

# Predicción del Éxito de Atracciones Turísticas: Un Enfoque de Deep Learning

Práctica del Módulo de Deep Learning - KeepCoding

LUIS MATA AGUILAR  
oekkgo@gmail.com

May 11, 2025

## 1 Objetivo

El presente proyecto tiene como objetivo principal desarrollar e implementar un modelo avanzado de Deep Learning que permita predecir con precisión el nivel de engagement que generarán distintos puntos de interés (POIs) turísticos. Este modelo integrará de manera innovadora dos fuentes de información complementarias: características visuales extraídas de imágenes y metadatos estructurados asociados a cada POI.

Los datos utilizados en este estudio provienen de la plataforma **Artgonuts**, garantizando así su relevancia y aplicabilidad en contextos reales del sector turístico. Las imágenes empleadas han sido específicamente procesadas para los fines de esta práctica, siendo sus versiones originales en alta resolución procedentes de diversas fuentes, incluyendo el portal de datos abiertos de la Comunidad de Madrid.

El desafío central consiste en desarrollar un sistema capaz de anticipar con exactitud el nivel de interacción que cada POI generará, basándose tanto en sus atributos visuales como en sus metadatos descriptivos. Esta capacidad predictiva representa un activo estratégico significativo para plataformas como Artgonuts<sup>1</sup>, ya que permite:

- Optimizar la selección y priorización de contenido para maximizar la interacción del usuario

---

<sup>1</sup>Si bien este proyecto se presenta como parte de una práctica formativa enmarcada en un caso realista, la empresa Artgonuts no requiere el desarrollo de estos modelos ni empleará sus resultados. Su contribución se limita únicamente a la cesión de datos provenientes de su plataforma.

- Identificar patrones visuales y características que correlacionan con mayor engagement
- Mejorar la experiencia del usuario al destacar contenido más relevante y atractivo
- Proporcionar insights data-driven para la toma de decisiones sobre nuevos POIs

El modelo desarrollado actuará como un clasificador, determinando si un punto de interés turístico (POI) generará un nivel de engagement alto o bajo entre los usuarios. Esta predicción se fundamentará en dos tipos de información complementaria:

- **Características visuales:** Extraídas mediante redes neuronales convolucionales (CNN) que analizarán patrones, colores, composición y elementos distintivos presentes en las imágenes de cada POI. Estas redes son capaces de identificar automáticamente atributos visuales que resultan atractivos para los usuarios.
- **Metadatos estructurados:** Información contextual como ubicación geográfica (coordenadas, distrito, barrio), categorización (tipo de atracción, temática), horarios, accesibilidad y otros atributos descriptivos que pueden influir significativamente en el interés que genera cada POI.

Este enfoque híbrido multimodal permite capturar la complejidad del comportamiento del usuario, integrando tanto la respuesta estética inmediata provocada por los elementos visuales como los factores prácticos y contextuales representados en los metadatos. La combinación de ambas fuentes de información en un único modelo proporciona una capacidad predictiva superior a la que se obtendría utilizando cada tipo de datos por separado, constituyendo así una herramienta estratégica para la optimización y personalización del contenido en plataformas turísticas.

## 2 Descripción del Dataset

El dataset utilizado contiene información detallada sobre puntos de interés (POIs) turísticos, estructurada de la siguiente manera:

- **Imágenes:** Cada POI incluye una imagen principal representativa, almacenada en carpetas individuales identificadas por el ID único del

punto de interés. La ruta a estas imágenes se encuentra en la columna `main_image_path`.

- **Metadatos:** Información contextual sobre cada POI, incluyendo:
  - `id`: Identificador único para cada punto de interés.
  - `name`: Nombre descriptivo del POI.
  - `shortDescription`: Breve descripción textual del punto de interés.
  - Ubicación geográfica: Coordenadas (`locationLon`, `locationLat`), barrio, distrito.
  - Categorización: Columna `categories` que indica el tipo de atracción o temática.
  - `tier`: Clasificación por nivel de relevancia o popularidad.
  - `tags`: Etiquetas descriptivas asociadas al POI.
  - `xps`: Experiencia obtenida por el usuario al visitar el POI (para gamificación).
- **Métricas de engagement:** Indicadores cuantitativos de la interacción de los usuarios con cada POI:
  - `Visits`: Número de visitas registradas.
  - `Likes` y `Dislikes`: Cantidad de valoraciones positivas y negativas recibidas.
  - `Bookmarks`: Número de veces que el POI ha sido añadido a favoritos.

Es importante destacar que para el desarrollo del modelo no es necesario utilizar todas las variables disponibles en el dataset. El alumno tiene la libertad de seleccionar el subconjunto de columnas que considere más relevante para el problema, siempre que pueda justificar adecuadamente esta selección. Esta flexibilidad permite al estudiante concentrarse en los aspectos fundamentales del desarrollo del modelo de deep learning, evitando complejidades innecesarias en el preprocesamiento de datos o en la definición de la arquitectura.

El dataset completo se encuentra disponible en formato ZIP, accesible a través de Google Drive (o alternativamente en GitHub). La estructura de archivos está organizada jerárquicamente, donde cada punto de interés tiene asignada una carpeta propia identificada por su ID único, conteniendo la imagen correspondiente y vinculada a sus metadatos en los archivos de datos estructurados.

## 3 Metodología

### 3.1 Preparación y Análisis de Datos (25%)

- **Análisis exploratorio del dataset:** Examen detallado de la distribución y características de los datos, identificación de patrones, correlaciones y posibles anomalías.
- **Preprocesamiento de datos:** Transformación de los datos brutos en un formato adecuado para el entrenamiento del modelo:
  - **Imágenes:** Normalización de valores de píxeles, redimensionamiento a dimensiones uniformes, ajustes de contraste o brillo si fuera necesario.
  - **Tratamiento de valores faltantes:** Implementación de estrategias para manejar datos incompletos (imputación, eliminación, etc.).
  - **Codificación de variables categóricas<sup>2</sup>:** Transformación de variables cualitativas en representaciones numéricas mediante técnicas como embedding, target encoding, o agrupación de categorías poco frecuentes.
- **Creación de métrica de engagement<sup>3</sup>:** Desarrollo de una variable objetivo que sintetice las diferentes métricas de interacción disponibles (likes, visitas, bookmarks, etc.) en un indicador único y significativo del éxito de cada POI.
- **División estratificada del dataset:** Partición de los datos en conjuntos de entrenamiento, validación y prueba, asegurando una distribución equilibrada de las clases o valores de la variable objetivo.
- **(Opcional) Data augmentation:** Implementación de técnicas de aumento de datos para imágenes, como rotaciones, volteos, cambios de escala o modificaciones de brillo/contraste, para enriquecer el conjunto de entrenamiento y mejorar la robustez del modelo.

---

<sup>2</sup>Se valorará la experimentación con diferentes técnicas de codificación de variables categóricas. Un one hot encoding de miles de categorías no tiene sentido en esta práctica, pensemos antes de aplicarla.

<sup>3</sup>Se valorará la experimentación con diferentes métricas de engagement. Es muy importante que el alumno justifique su elección y explique el porqué de su elección. Esta variable será la Y a predecir del modelo (estamos trabajando con datos no etiquetados).

### 3.2 Arquitectura del Modelo (35%)

- **Desarrollo de un modelo funcional:** Implementación de una arquitectura que demuestre comprensión de los principios fundamentales de deep learning vistos en clase.
  - Preferentemente modelo híbrido que combine:
    - \* Componente visual: Red convolucional para procesamiento de imágenes (propia o adaptada)
    - \* Componente contextual: Procesamiento de metadatos mediante capas fully-connected
    - \* Mecanismo de fusión de ambas ramas de información
  - Experimentación con diferentes configuraciones arquitectónicas:
    - \* Posibilidad de utilizar modelos pre-entrenados como base (ResNet, EfficientNet)
    - \* Adaptación y personalización de las arquitecturas según las necesidades del problema
- **Justificación detallada de decisiones arquitectónicas:**
  - Explicación razonada de cada componente del modelo
  - Análisis de alternativas consideradas y motivos de selección final
  - Prevención explícita de data leakage en el diseño del modelo
- **Originalidad y aplicación de conocimientos:**
  - Evidencia de desarrollo propio siguiendo los principios aprendidos en clase
  - Adaptaciones específicas para el problema de predicción de engagement

### 3.3 Entrenamiento y Optimización (25%)

- **Implementación del pipeline de entrenamiento:** Desarrollo de un proceso completo para entrenar el modelo con los datos preparados.
- **Entrenamiento efectivo del modelo:** El objetivo principal es conseguir un modelo funcional cuyo rendimiento supere claramente al de un clasificador aleatorio.

- **Documentación del proceso experimental:** Registro detallado de los experimentos realizados, incluyendo configuraciones, resultados y observaciones.
- **(Opcional) Optimización de hiperparámetros:** Si bien no es obligatorio, la experimentación con diferentes configuraciones ayudará a mejorar el rendimiento:
  - Pruebas con diferentes tasas de aprendizaje (learning rates)
  - Experimentación con distintos optimizadores (Adam, SGD, etc.)
  - Ajuste de parámetros como batch size y número de épocas
- **Implementación básica de técnicas anti-overfitting:** Aplicación de al menos una estrategia para prevenir el sobreajuste:
  - Dropout en capas apropiadas
  - Regularización (L1/L2) donde sea conveniente
  - Monitorización del rendimiento en validación para detección temprana de overfitting

### 3.4 Evaluación y Análisis (15%)

- **Evaluación en conjunto de test:** Verificación del rendimiento del modelo en datos no vistos durante el entrenamiento.
- **Interpretación de resultados:** Explicación fundamentada de los resultados en el contexto del problema de engagement, conectando el rendimiento técnico con las implicaciones prácticas.
- **(Opcional) Análisis de métricas de rendimiento:** Interpretación detallada de las métricas obtenidas (precisión, recall, F1-score) y su significado en el contexto del problema.
- **(Opcional) Interpretabilidad del modelo:** Técnicas para entender qué características influyen en las predicciones y cómo el modelo toma decisiones.
- **(Opcional) Análisis de errores y casos específicos:** Estudio de los falsos positivos/negativos más representativos para comprender las limitaciones del modelo.

- **(Opcional) Visualización de features importantes:** Representación gráfica de las características más relevantes para la predicción mediante técnicas como mapas de calor o Grad-CAM.
- **(Opcional) Propuestas de mejoras futuras:** Recomendaciones basadas en el análisis para optimizar el modelo en iteraciones posteriores.

## 4 Entregables

1. **Notebook con código comentado y reproducible:** Debe incluir un archivo `requirements.txt` o `environment.yml` que permita reproducir el entorno de desarrollo. Todo el código debe utilizar semillas (`random_seed`) para garantizar la reproducibilidad de los resultados.
2. **Memoria técnica detallada:** Documento PDF que explique exhaustivamente todo el proceso seguido, incluyendo tanto los éxitos como los fracasos iniciales. Es fundamental documentar la metodología completa, independientemente de los resultados obtenidos. **Es obligatorio que se entregue la memoria técnica en formato PDF para evaluar el proyecto.**
3. **Modelo entrenado final:** Versión final del modelo con sus pesos y configuración.
4. **Scripts de preprocesamiento y utilidades:** Código auxiliar utilizado durante el desarrollo del proyecto.

## 5 Criterios de Evaluación

- **Calidad del código y documentación:** Código legible, bien estructurado y documentado. Si se ha utilizado asistentes de IA para generar código (no recomendado), debe atribuirse claramente su uso.
- **Rigurosidad del análisis:** Profundidad y precisión en el análisis de datos y resultados.
- **Rendimiento del modelo final:** Efectividad de la solución implementada. Aunque no es necesario que el modelo sea perfecto, es importante que se complete el trabajo y que el modelo pueda ser entrenado.

Se valorará positivamente el esfuerzo realizado y se proporcionará feedback detallado en la entrega y en tutorías para ayudar a mejorar la versión final. ¡No estáis solos en este proceso!

- **Creatividad en el enfoque:** Originalidad en las soluciones propuestas. ¡No tengáis miedo de volveros locos, esto puede ser divertido, disfrutadlo! Las ideas más innovadoras a veces surgen cuando nos permitimos experimentar sin restricciones.
- **Reproducibilidad del proyecto:** Capacidad de replicar completamente el trabajo realizado siguiendo la documentación proporcionada, gracias al uso de semillas y la especificación detallada del entorno.

## 6 Comentarios finales

Este proyecto representa una excelente oportunidad para poner en práctica los conocimientos adquiridos en deep learning y enfrentarse a un problema real de clasificación de imágenes. Se anima a los estudiantes a:

- Explorar soluciones creativas y originales más allá de las aproximaciones convencionales
- Documentar detalladamente el proceso de experimentación, **incluyendo tanto los éxitos como los fracasos**
- Mantener una mentalidad de aprendizaje continuo, aprovechando cada desafío como una oportunidad de crecimiento
- Aprender en conjunto, no en solitario. Utilizar grupos de aprendizaje o compartir dudas por Discord está probado que funciona muy bien para mejorar la comprensión y retención de conceptos
- ¡Romper esquemas! Atrévete a pensar fuera de la caja y sorpréndenos con soluciones que nadie haya imaginado
- Contar tu historia completa: los momentos "¡Eureka!" y los "¿Qué demonios está pasando?" son igualmente valiosos en tu **documentación del proceso**
- Experimentar sin miedo al fracaso - ¡los grandes innovadores tropezaron cientos de veces antes de cambiar el mundo!



Recuerda que el objetivo principal no es solo conseguir la mejor métrica posible, sino desarrollar una comprensión profunda de las técnicas de deep learning y su aplicación práctica. ¡Mucho ánimo y disfruta del aprendizaje!